DE LA INCERTIDUMBRE A LA PRECISIÓN!



¡CALIDAD DE DATOS!

Escuela de Valuación Miguel Camacaro

De la Incertidumbre a la Precisión: Análisis, Saneamiento e Inferencia de Datos

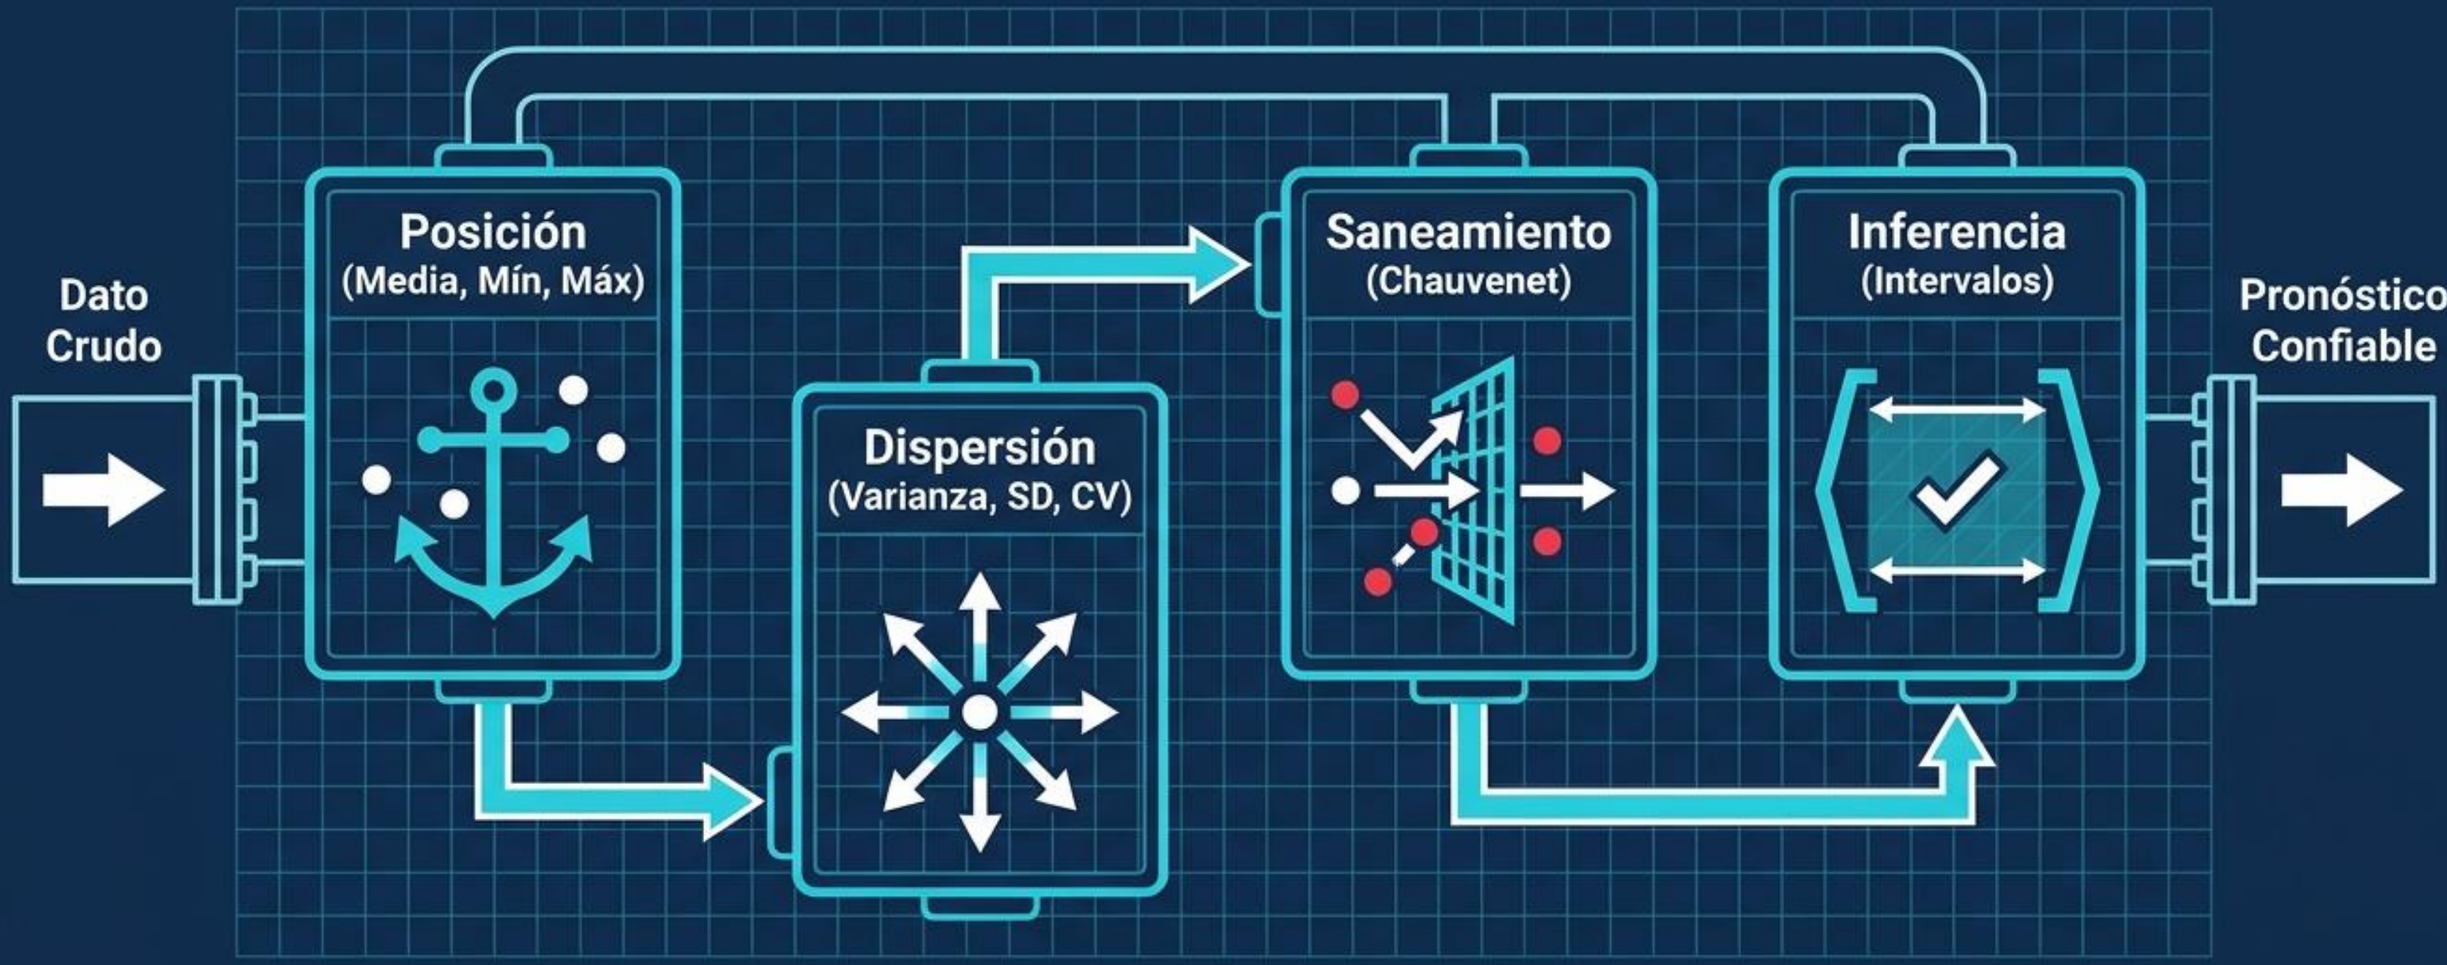
Manual Operativo de Calidad de Datos



Escuela de Valuación Miguel Camacaro

Gemini Notebook

El Ciclo de Refinamiento de la Muestra



Gemini Notebook

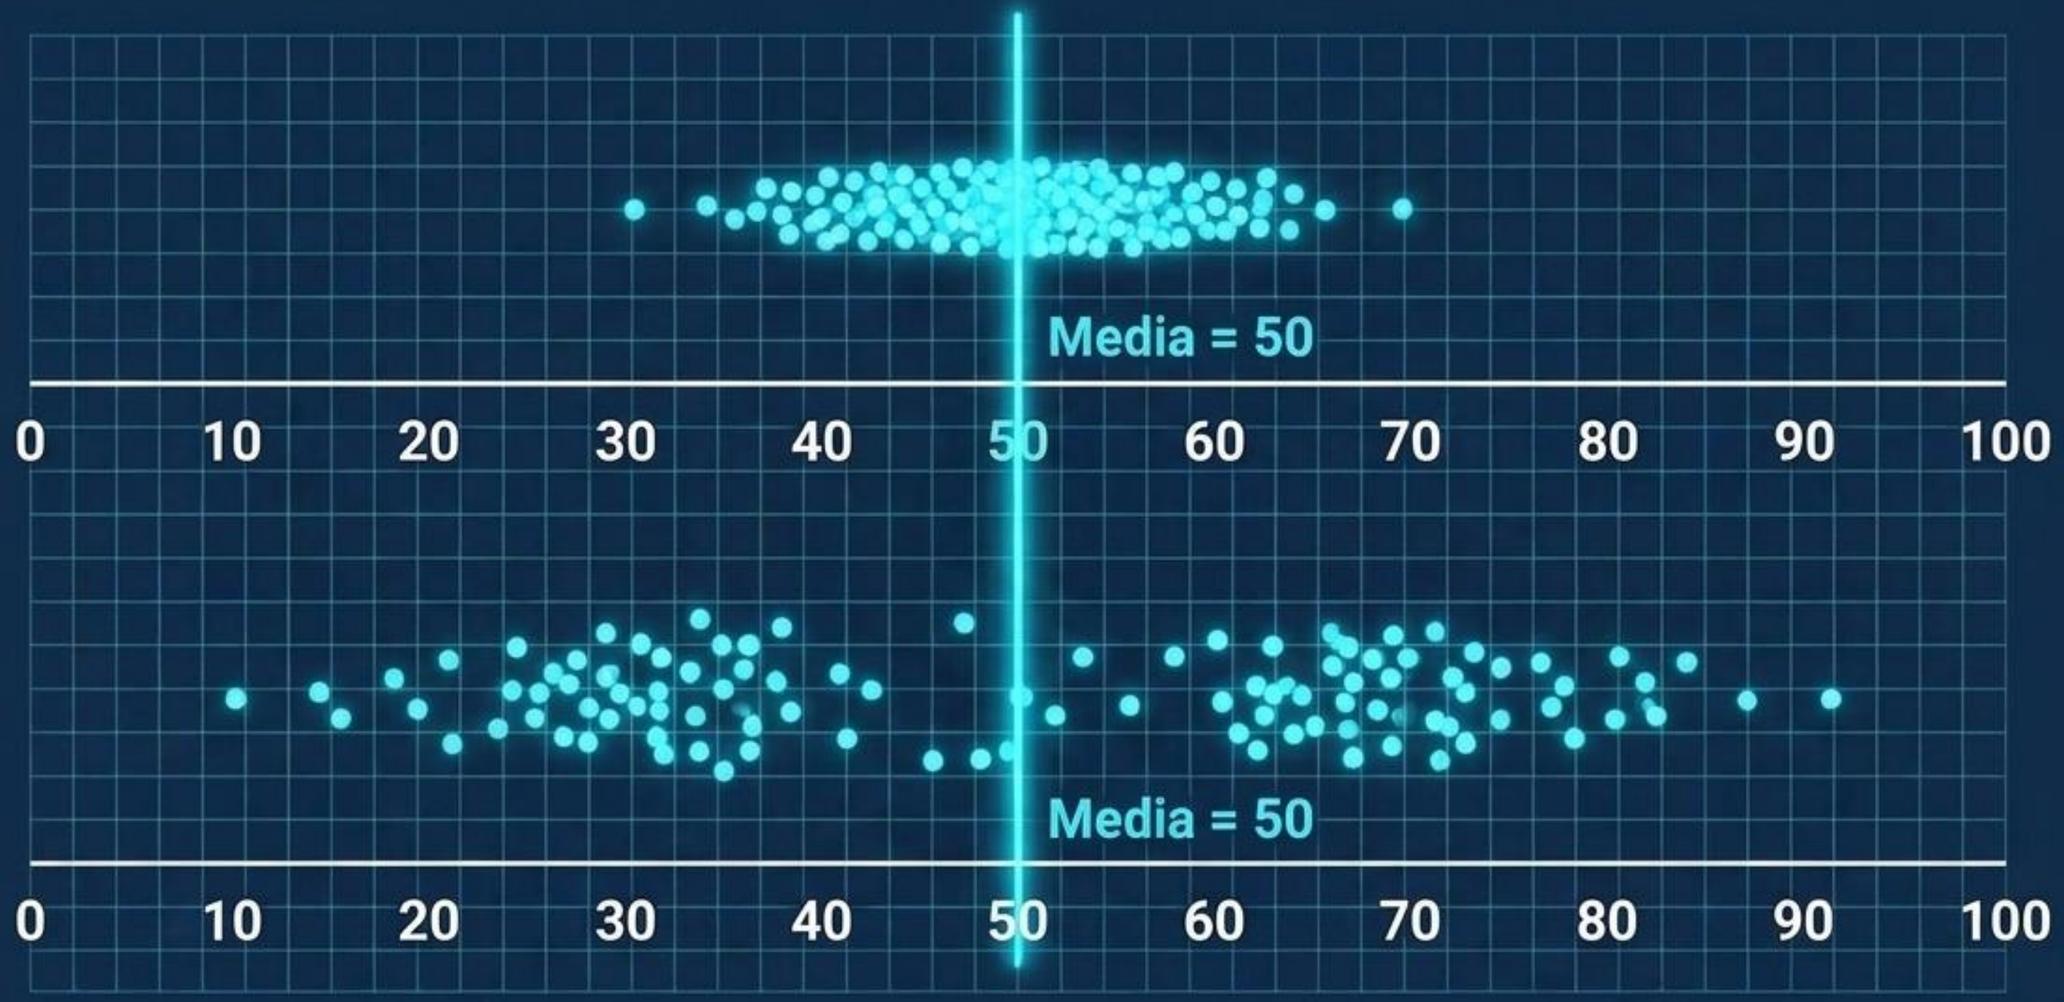
El Ancla del Dato (Mínimo, Máximo y Media)



El Rango es la medida de dispersión más primitiva. Proporciona la amplitud total, pero es estadísticamente ciego a la distribución de los datos en el medio.

Gemini Notebook

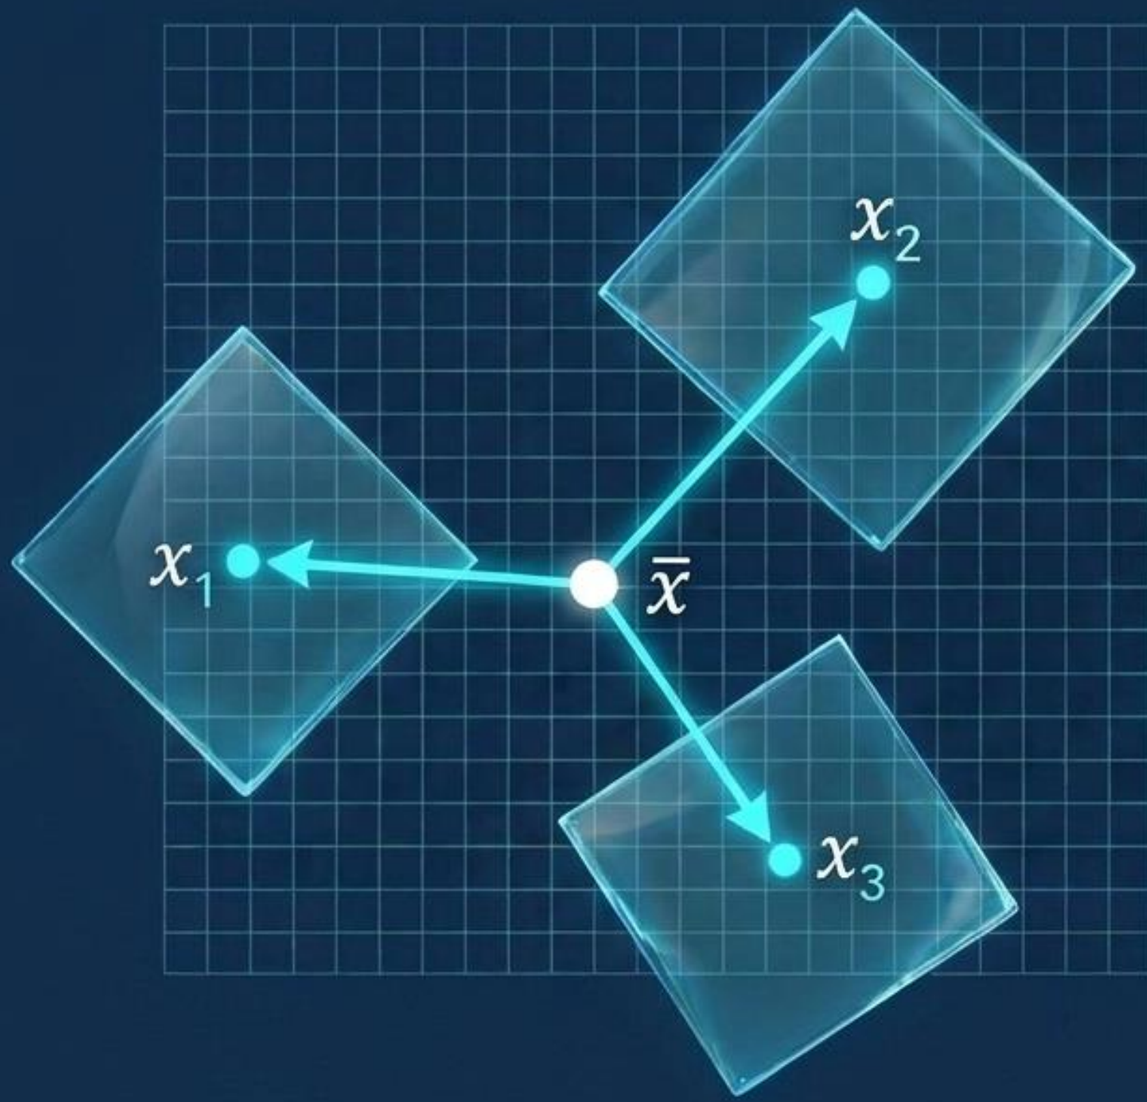
La media por sí sola es un espejismo estadístico



Dos muestras pueden tener el mismo centro de gravedad, pero perfiles de riesgo y variabilidad completamente diferentes. Necesitamos métricas que capturen la incertidumbre.

Gemini Notebook

Varianza (s^2): El motor matemático de la variabilidad



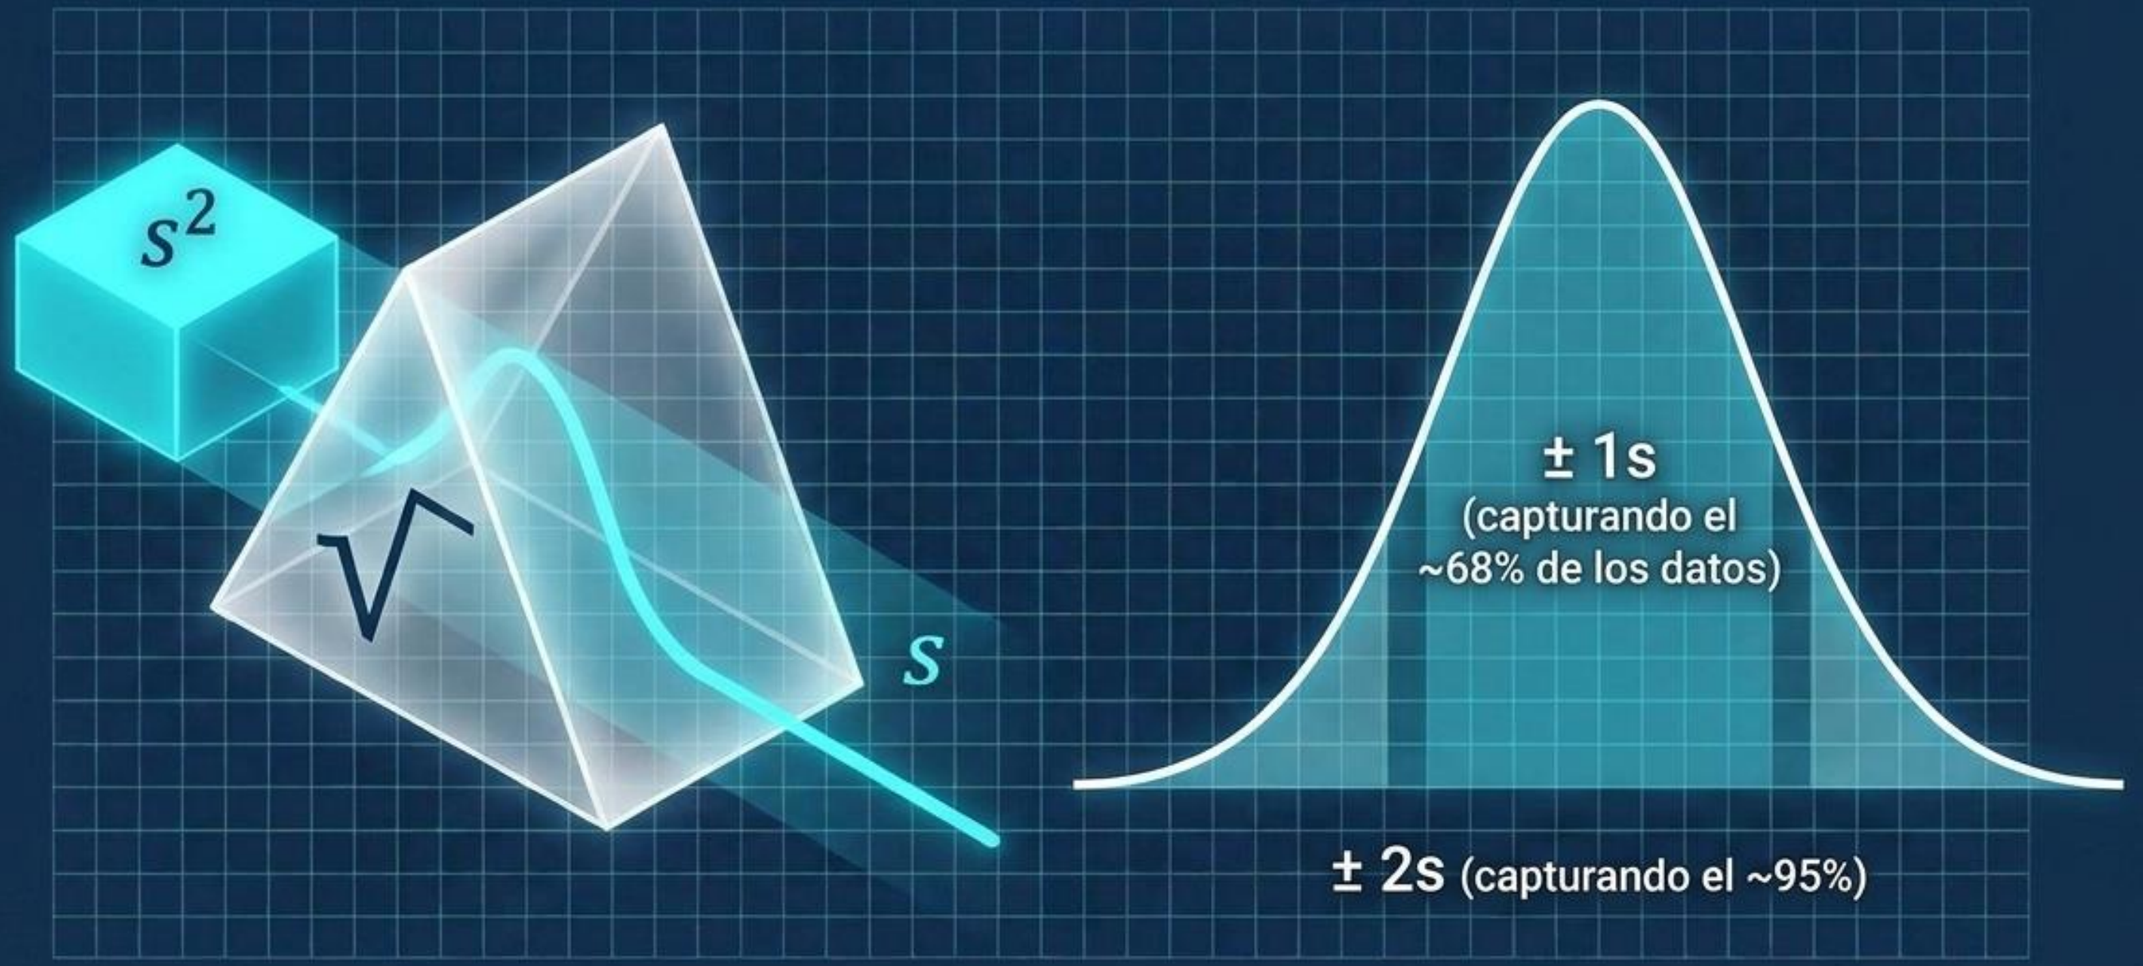
Elevar al cuadrado evita que distancias positivas y negativas se cancelen a cero, y penaliza severamente los valores extremos.

$$s^2 = \frac{\sum (x_i - \bar{x})^2}{n - 1}$$

Resulta en unidades cuadradas, lo cual es difícil de interpretar directamente.

Gemini Notebook

Desviación Estándar (s): El retorno a la escala original



La desviación estándar traduce la dispersión matemática nuevamente a las unidades originales, permitiéndonos crear zonas de expectativa realistas.

Gemini Notebook

El ajuste de seguridad: Población vs. Muestra

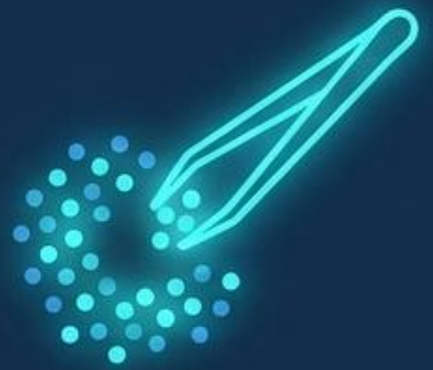
Población Total



Tamaño: N
Media: μ
Desviación: σ

$$\sigma^2 = \frac{\sum(x_i - \mu)^2}{N}$$

Muestra Seleccionada



Tamaño: n
Media: $\bar{x}$
Desviación: s

$$s^2 = \frac{\sum(x_i - \bar{x})^2}{n - 1}$$

La Corrección de Bessel (n-1)

Las muestras, por naturaleza, subestiman la variabilidad real del universo. Al dividir por un número más pequeño (n-1), inflamos ligeramente nuestra medida de dispersión para protegernos de esta falsa seguridad.

Gemini Notebook

Coeficiente de Variación (CV): Midiendo peras contra manzanas

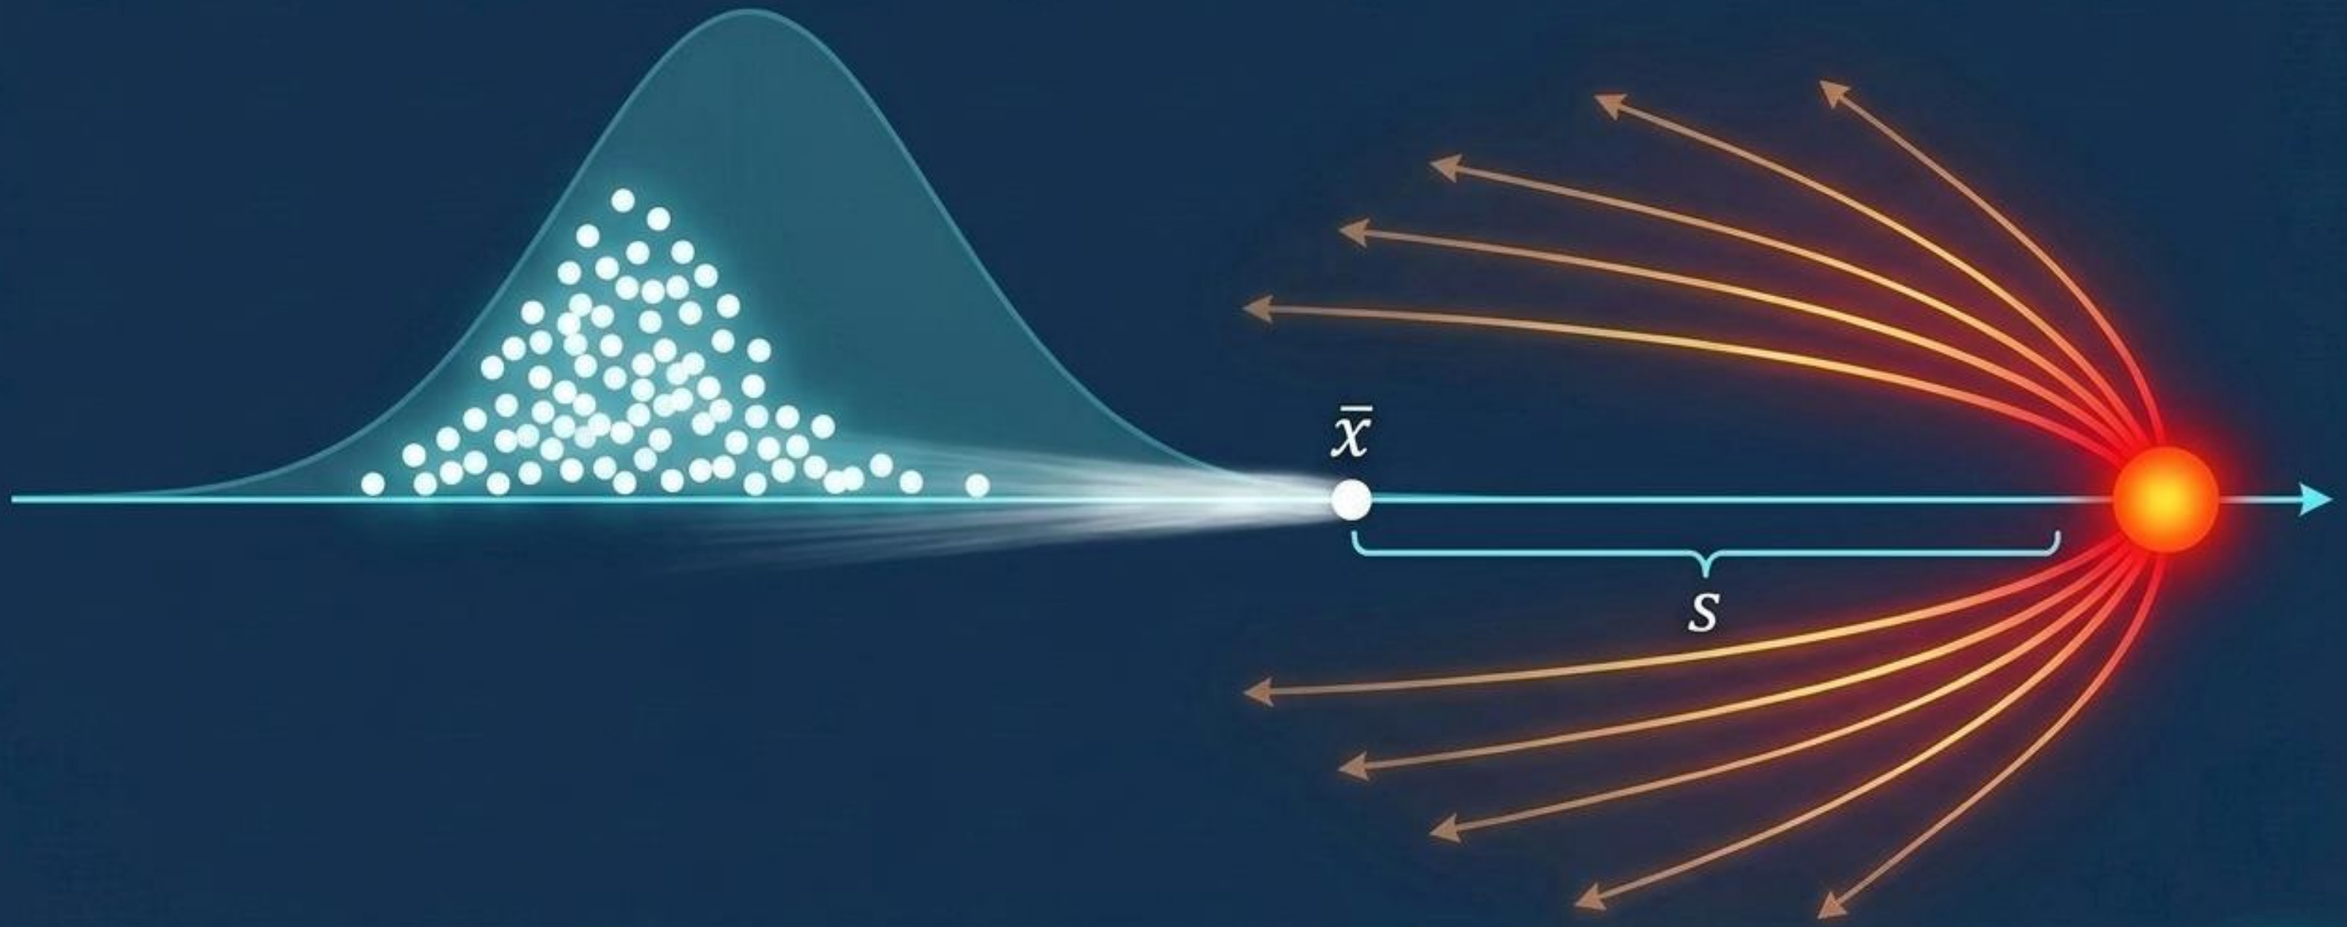
$$CV = \frac{s}{\bar{x}} \times 100$$

1		**≤ 7%** : Estimación de Alta Precisión (Distribución altamente homogénea).
2		**8% - 14%** : Precisión Aceptable (Variabilidad estándar).
3		**15% - 20%** : Precisión Regular (Precaución al inferir).
4		**> 20%** : Poco Preciso (Alta heterogeneidad de datos).

Es una medida relativa y adimensional. Fundamental cuando las medias de dos grupos son drásticamente distintas o se miden en diferentes unidades.

Gemini Notebook

La vulnerabilidad del modelo: La amenaza de los Datos Atípicos

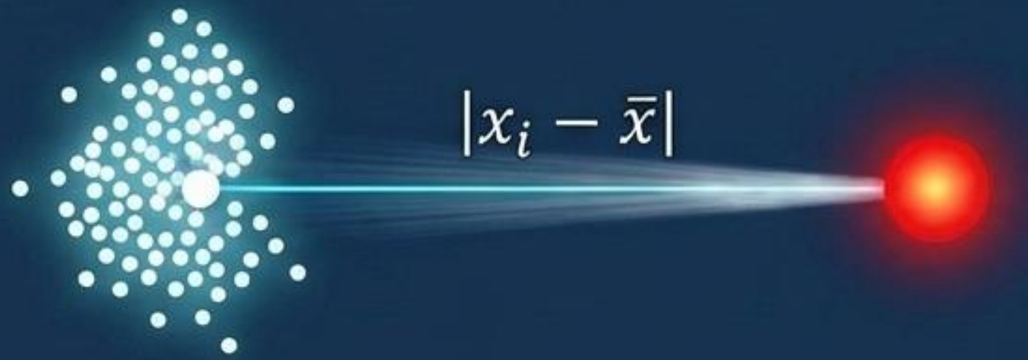


Errores de captura, fallas de sensores o eventos excepcionales destruyen la representatividad. Antes de concluir algo, la muestra debe ser saneada.

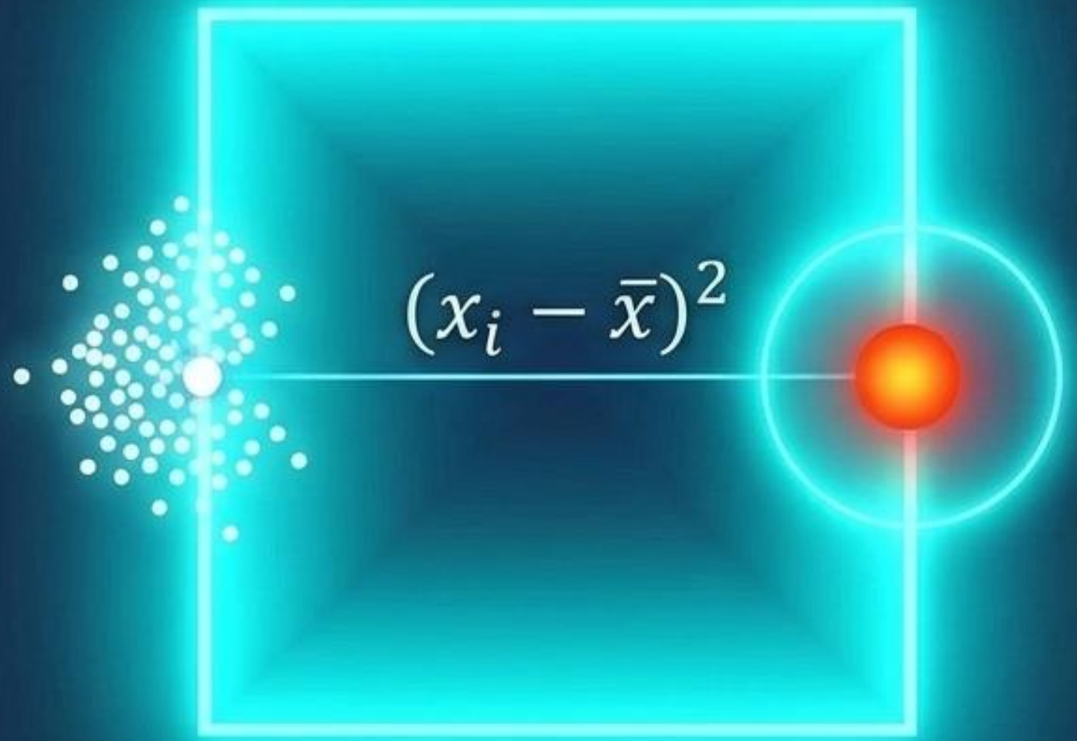
Gemini Notebook

Hipersensibilidad al ruido: El detector de anomalías perfecto

Desviación Media Absoluta



Desviación Estándar



Debido a que eleva al cuadrado las diferencias, la desviación estándar es alérgica a los valores atípicos. Esta debilidad la convierte en el gatillo perfecto para activar los protocolos de saneamiento.

Gemini Notebook

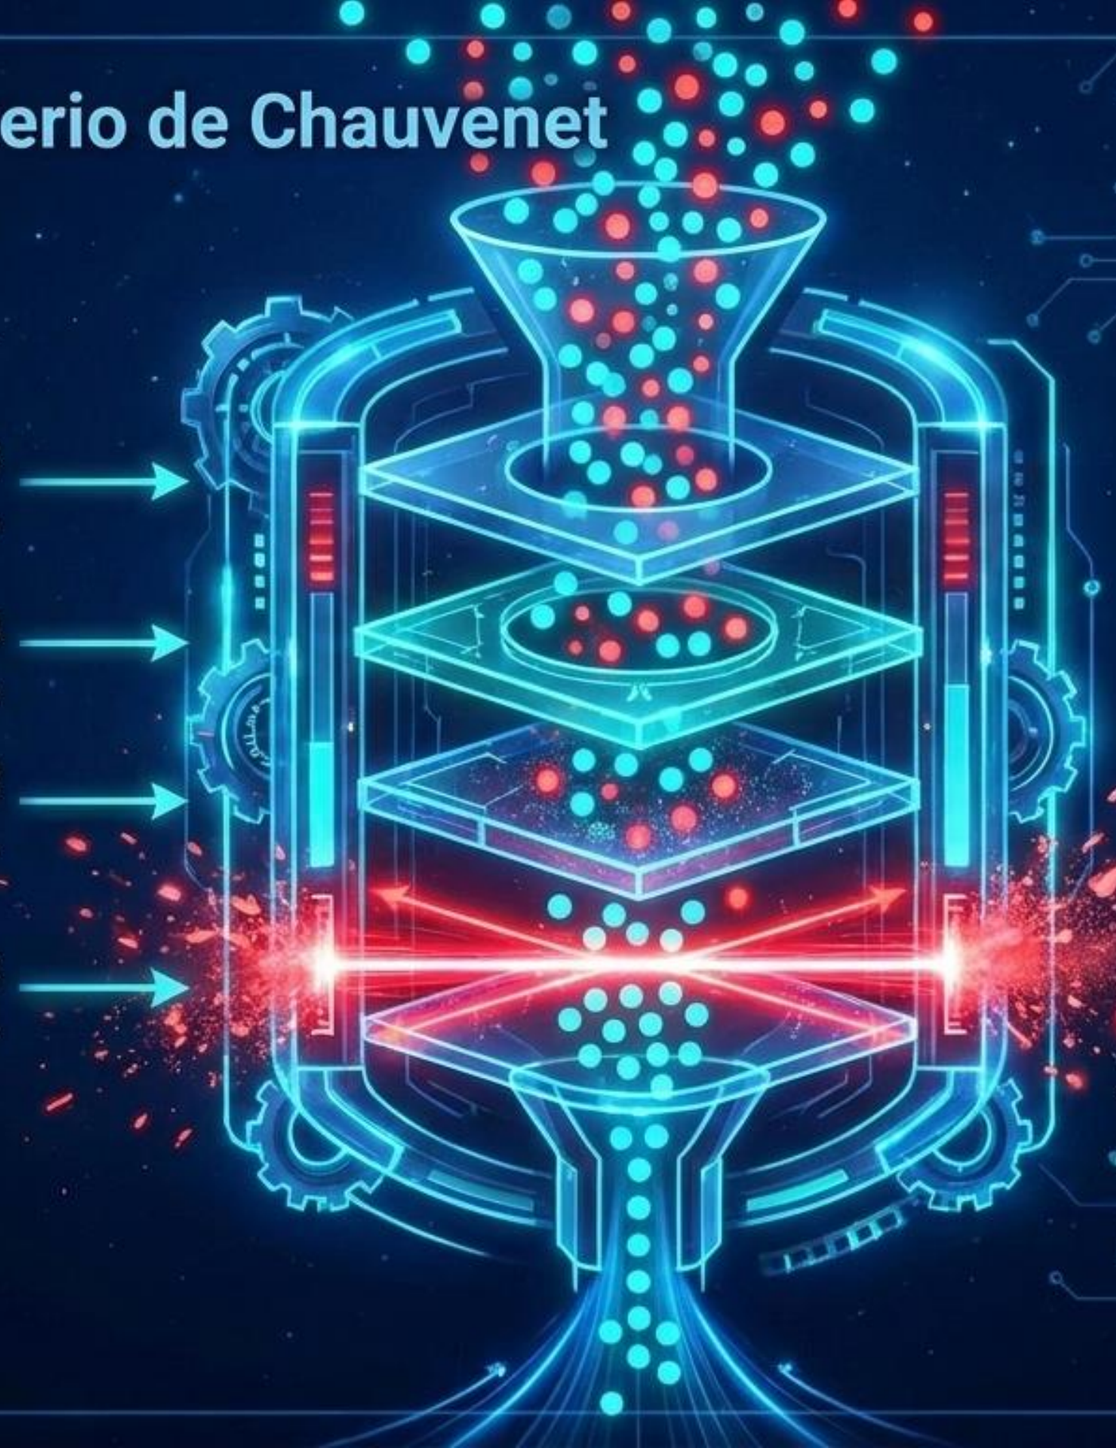
El Filtro Purificador: Criterio de Chauvenet

1. Calibración: Se calcula $\bar{x}$ y s de la muestra.

2. Evaluación: Probabilidad teórica de desviación bajo curva normal.

3. Proyección: Probabilidad multiplicada por tamaño de muestra (n).

4. Decisión: Si el umbral es < 0.5, expulsar.



Gemini Notebook

El Saneamiento en Acción: Restaurando la geometría de los datos

Muestra Contaminada, n=20

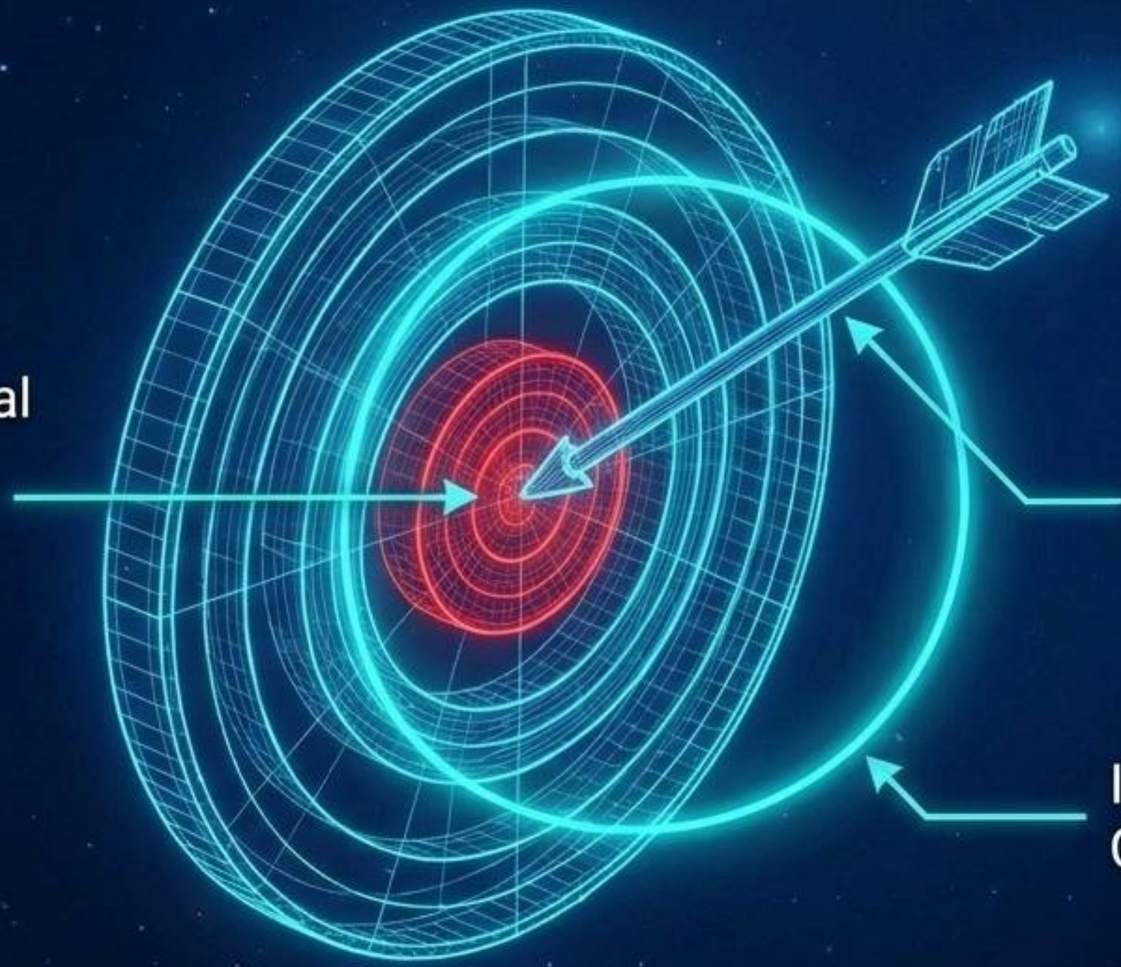


Muestra Saneada, n=19



Gemini Notebook

Inferencia: El margen geométrico de la verdad poblacional



El parámetro poblacional verdadero (μ), siempre desconocido.

Nuestro estimador puntual ($\bar{x}$).

Intervalo de Confianza.

No podemos garantizar clavar la flecha en el centro exacto, pero podemos calcular un radio matemático alrededor de nuestra flecha que atrapa el centro con un 95% de seguridad.

Gemini Notebook

Ensamblando el Intervalo de Confianza

El punto de anclaje ajustado.

Factor de seguridad (Multiplicador, ej. 1.96 para 95% de certeza).

$$IC = \bar{x}_{san} \pm \left(Z_{\alpha/2} \times \frac{s_{san}}{\sqrt{n_{san}}} \right)$$

El Error Estándar (La incertidumbre, purificada del ruido).

¡Ajuste de parámetros!
Al calcular el intervalo, es obligatorio usar los valores actualizados de la muestra saneada. El tamaño de muestra 'n' debe reflejar la eliminación de los valores atípicos (ej. de 50 a 48 datos).

Gemini Notebook

Cheat Sheet: El Protocolo de Calidad de Datos

Varianza Muestral (s^2)



Desviación Estándar (s)



Coeficiente de Variación (CV)



$$CV = \frac{s}{\bar{x}}$$

Umbral de Chauvenet

(Lógica probabilística)



$$P < \frac{1}{2n}$$

Intervalo de Confianza (IC)

$$\bar{x} \pm ME$$



Los datos limpios no son un accidente estadístico; son el resultado de un escrutinio metodológico disciplinado. Confíe en el proceso, no en la intuición.

Gemini Notebook